

Clasificador De Frutas Según Su Tipo Y Estado De Maduración Para Mejora En Los Procesos De Logística De Bancos De Alimentos

Daniel Andres Rojas Paredes

Luis Alberto Chavez Castro

UNIVERSIDAD NACIONAL DE COLOMBIA

Facultad de Ingeniería

Depto. Mecánica y Mecatrónica

Técnicas de Inteligencia Artificiales

Bogotá

II - 2022



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Contenido

1. Contextualización
2. Estado del Arte
3. Solución propuesta
4. Arquitectura implementada
5. Regularización y optimización de Hiperparametros
6. Conclusiones



1.Contextualización

- “Un tercio de todos los alimentos que producimos se pierde o desperdicia debido a prácticas inadecuadas, cuando 870 millones de personas pasan hambre todos los días.”

-- José Graziano da Silva, 2014
director general de la FAO,



12 PRODUCCIÓN
Y CONSUMO
RESPONSABLES




2 HAMBRE
CERO





- Gestión de donantes
- Gestión De producto
- Gestión de beneficiarios

2 Estado del arte



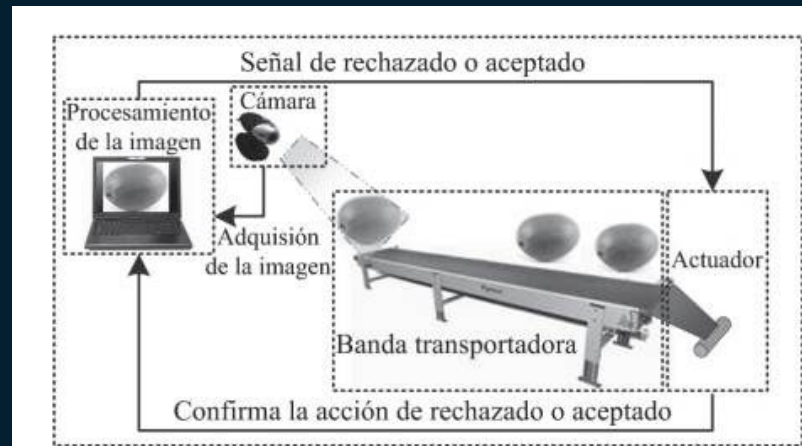
- DESARROLLO DE UNA APLICACIÓN MÓVIL PARA EL RECONOCIMIENTO DE LA MADUREZ DE UN GRUPO DE FRUTAS A TRAVÉS DEL ANÁLISIS DE IMÁGENES POR MEDIO DE REDES NEURONALES MENDEZ ALMANSA ESTEBAN . SILVA SALAMANCA SEBASTIAN- 2021
- Sanchez Rios, Santiago (abr. de 2022). Control de Calidad de Frutas Jetson Nano
- Foong, Chai C., Goh K. Meng y Lim L. Tze (ago. de 2021). "Convolutional Neural Network based Rotten Fruit Detection using ResNet50"

Primeras aproximaciones




3 Solución Propuesta

- > *La creación de una red neuronal convolucional a través del framework pythorch que inicialmente pueda diferenciar entre 3 estados de la fruta, planteando los cimientos para una escalabilidad que permita el fácil entrenamiento de la red para que sea aplicable a varios alimentos perecederos.*




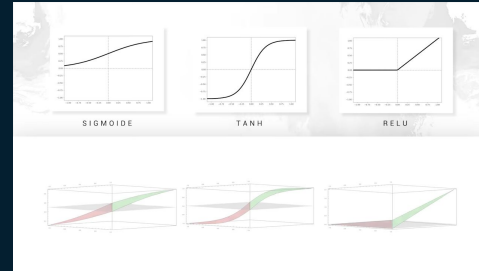

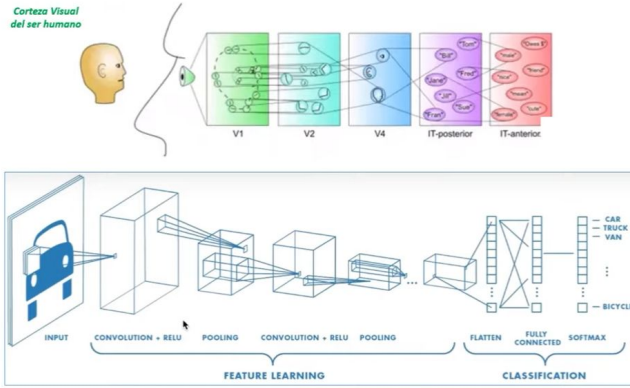
4.1 Datasets y Dataloaders



Split de los datasets
505 mandarinas 4700 bananas
Batch size 32
Num workers :4
[0,1,2]=verde,maduro,dañado

4.2 Arquitectura implementada

Redes neuronales convolucionales (CNN, ConvNet)

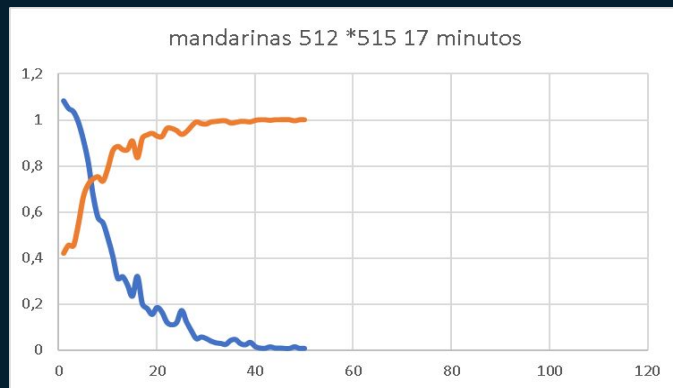




Fórmula para convoluciones

- La cantidad de canales de entrada C
- El tamaño del filtro/kernel F
- La cantidad de filtros K
- El padding P
- El stride S

$$C \times I \times I \rightarrow K \times O \times O$$
$$O = \frac{I - F + 2P}{S} + 1$$

4.3 Primeros experimentos



5.1 Regularizacion

Normalización de imágenes

Los valores de el tensor van de 0 a 1 y no de 255 a 0

DropOut

Obliga a la red al generar redundancias, haciéndola más robusta, las activaciones remanentes se escalan por $1/(1-p)$
Con p dropout ratio

Batch norm


Normaliza la salida de cada capa convolucional para evitar explotar weight problem

5.2 Optimización de Hlperparametros


- ADAM NG

- Learning rate
- Momentum
- Mini-batch size
- Neuronas en cada layer
- Cantidad de layers


- BABYSITTING
- GRID SEARCH
- RANDOM SEARCH







Learning rate $1e-6$



Learning rate $1e-5$



5.3. Resultados



6 CONCLUSIONES

- Respecto al overfitting, con una época alrededor de 40, se comienza a estabilizar la pérdida.
- Entre más resolución tengan las imágenes a entrenar, más tiempo toma la red neuronal para entrenamiento pero así mismo tendrá la posibilidad de hacer distinción de detalles más finos en la forma de predecir, por ejemplo, con imágenes burdas distinguirá un estado de maduración del otro pero muy a groso modo. Con una mayor resolución puede distinguir que un banano esté más maduro que otro.
- Esperábamos un sobreentrenamiento en las imágenes de bananos de 128, al evaluarlo con el conjunto de datos de inferencia y revisar su desempeño este mejora dependiendo de la cantidad de épocas que se empleen, el mejor resultado lo obtuvimos con 12 épocas.

La importancia de entender cómo aprende una red

- **"No free lunch" theorems**
 - No existe un algoritmo de aprendizaje que sea una bala de plata
- **Leaky abstractions**
 - No se puede esperar una API mágica que haga todo el trabajo por nosotros (A. Karpathy)
- **Trabajo duro**
 - Modelo complejo (ej. Tiempo de cómputo)
 - Entendimiento de generalización
 - Visualización

Mas allá del estado del arte

- › <https://www.asimovinstitute.org/neural-network-zoo/>
- › **Tensorflow Playground**
- › **DotCSV canal de youtube Playlist inteligencia artificial**
- › **Cur**
- › <https://towardsdatascience.com/cross-entropy-negative-log-likelihood-and-all-that-jazz-47a95bd2e81>
- › <https://pytorch.org/>



¡GRACIAS!

¿Preguntas?